數據科學應用實務

大數據分析

- R/Python/Julia/SQL程式設計與應用 (R/Python/Julia/SQL Programming and Application)
- 資料視覺化 (Data Visualization)
- 機器學習 (Machine Learning)
- 統計品管 (Statistical Quality Control)
- 最佳化 (Optimization)

李明昌博士

https://www.youtube.com/@alan9956

http://rwepa.blogspot.com/

alan9956@gmail.com

大綱

1. 資料分析暨視覺化的心法【ai_01_apc_method.py】
2. AI與螺旋槳性能最佳化應用【ai_02_aeronautical_engineering.py】
3. AI與黃金價格深度學習預測應用(LSTM)【ai_03_gold_price.py】
4. 結論

1.資料分析暨視覺化的心法

大綱

- 1.1 RWEPA 簡介
- 1.2 資料分析架構暨APC方法
- 1.3 資料分析暨視覺化工具
- 1.4 資料分析與視覺化應用

1.1 RWEPA 簡介

RWEPA簡介 http://rwepa.blogspot.com/

- 姓名：李明昌 (ALAN LEE)
- 現職：中華R軟體學會 常務理事
  臺灣資料科學與商業應用協會 常務理事
- 學歷：中原大學 工業與系統工程所 博士
- 經歷：
  - 育達科技大學 資訊管理系(所) 兼任助理教授
  - 佛光大學 兼任教師
  - 國立台北商業大學 兼任教師
  - 東吳大學 兼任教師
  - 崇友實業 行銷企劃專員
  - 國航船務代理股份有限公司 海運市場運籌管理員

- 大專院校、資策會、工業技術研究院、國家發展委員會、中央氣象局、公平交易委員會、各縣市政府與日本名古屋產業大學等公民營單位演講達353餘場，3282小時以上。
- 連絡資訊：*alan9956@gmail.com*

- **iPAS 巨量資料分析師 證照推廣**
- **iPAS 營運智慧分析師 證照推廣**

1.2 資料分析架構暨APC方法

★★★資料分析架構暨APC方法

資料分析架構

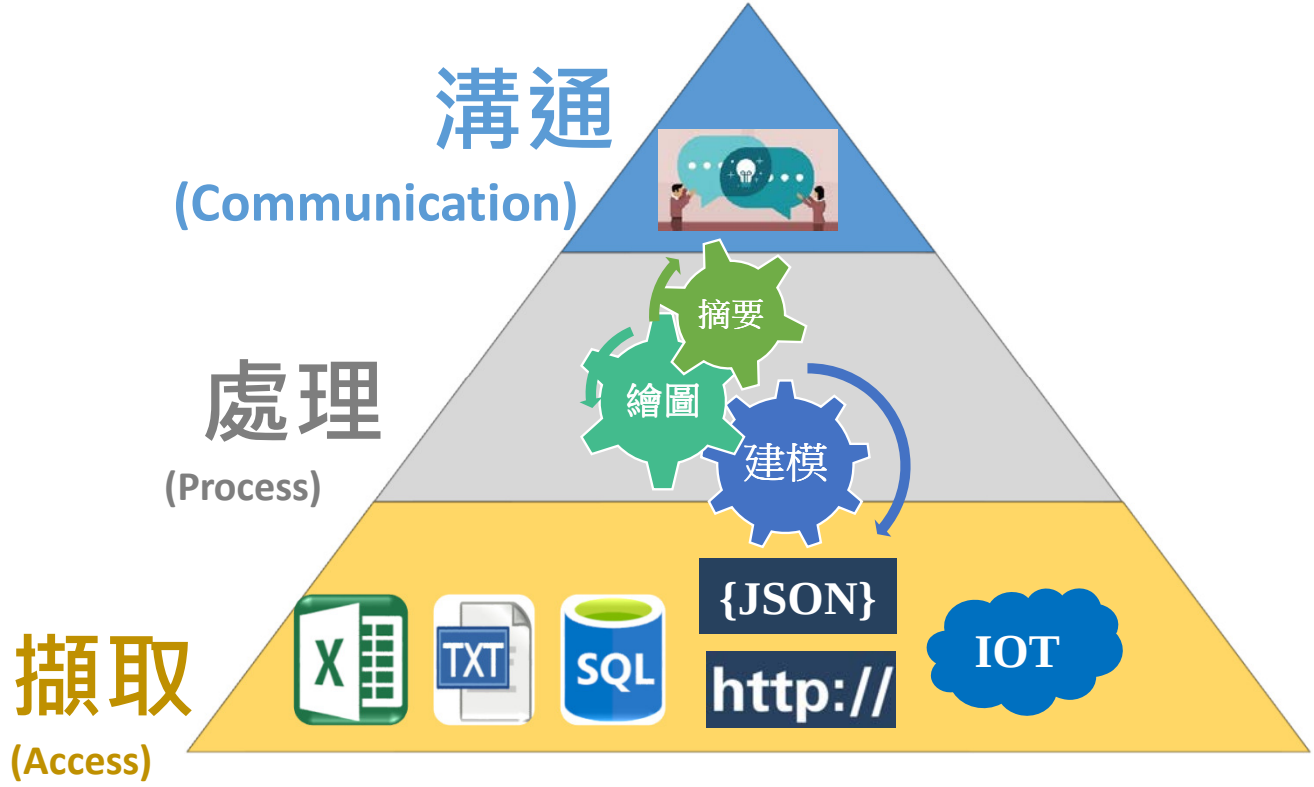

APC方法

1.

2.

3.

1.3 資料分析暨視覺化工具

資料分析暨視覺化工具

- R - http://rwepa.blogspot.com/ 【免費】
- Python - http://rwepa.blogspot.com/2020/02/pythonprogramminglee.html 【免費】
- Julia - https://julialang.org/ 【免費】
- PowerBI- https://powerbi.microsoft.com/zh-tw/ 【免費/付費】
- Tableau - https://www.tableau.com/ 【免費/付費】
- Excel 【付費】https://zh.wikipedia.org/zh-tw/Microsoft_Excel

大數據分析工具

- Microsoft Excel 2019: 104萬餘筆資料限制

	A	B	C	D	E	F	G
1	WEEK_END_DATE	STORE_NUM	UPC	UNITS	VISITS	HHS	SPEND
1048572	14-Jan-09	367	1111009477	13	13	13	18.07
1048573	14-Jan-09	367	1111009497	20	18	18	27.8
1048574	14-Jan-09	367	1111009507	14	14	14	19.32
1048575	14-Jan-09	367	1111035398	4	3	3	14
1048576	14-Jan-09	367	1111038078	3	3	3	7.5

1,048,576筆資料限制

大數據分析免費工具

軟體	Python	R	Julia
Released	1991	2000	2012
用途	程式語言 系統結合	統計,繪圖,視覺化 程式語言	科學計算 程式語言
版本	自由軟體 物件導向	自由軟體 物件導向	自由軟體 物件導向
附加功能	免費模組	免費套件	免費模組
使用者	工科+ 商管	商管+ 工科	商管+ 工科

Python 完全向下版本相容?

如何學習 Python?

- 熟悉教材內容
- 將教材內容的資料集改為工作資料集(企業, 學術)
- 遇到問題時, 想辦法尋找答案
- 掌握 APC方法
- 掌握 ①摘要 ②繪圖 ③建模
- 參考網路應用文章 (進階) & 學術論文

```
尋找答案 = {"方法1": "同事,同學,朋友等",
          "方法2": "Google",
          "方法3": "alan9956@gmail.com"}
```

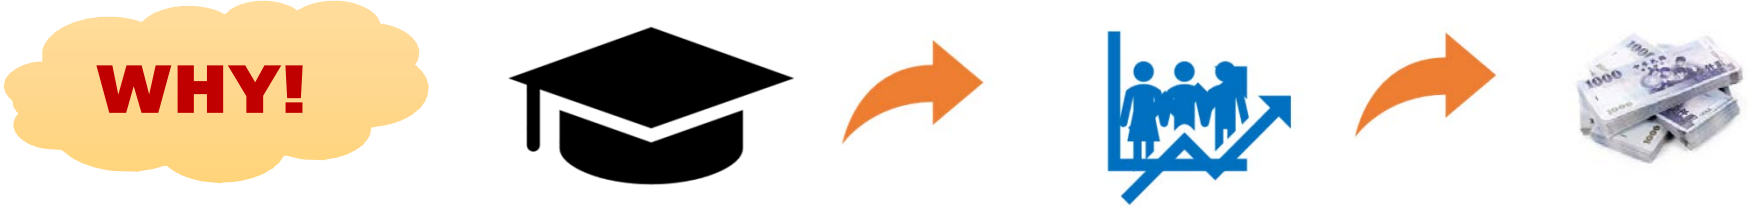

1.4 資料分析與視覺化應用

資料分析與視覺化應用

R + shiny, Python + Streamlit → 互動式網頁

地理資訊

空間圓餅圖離群值分析

氣象資訊

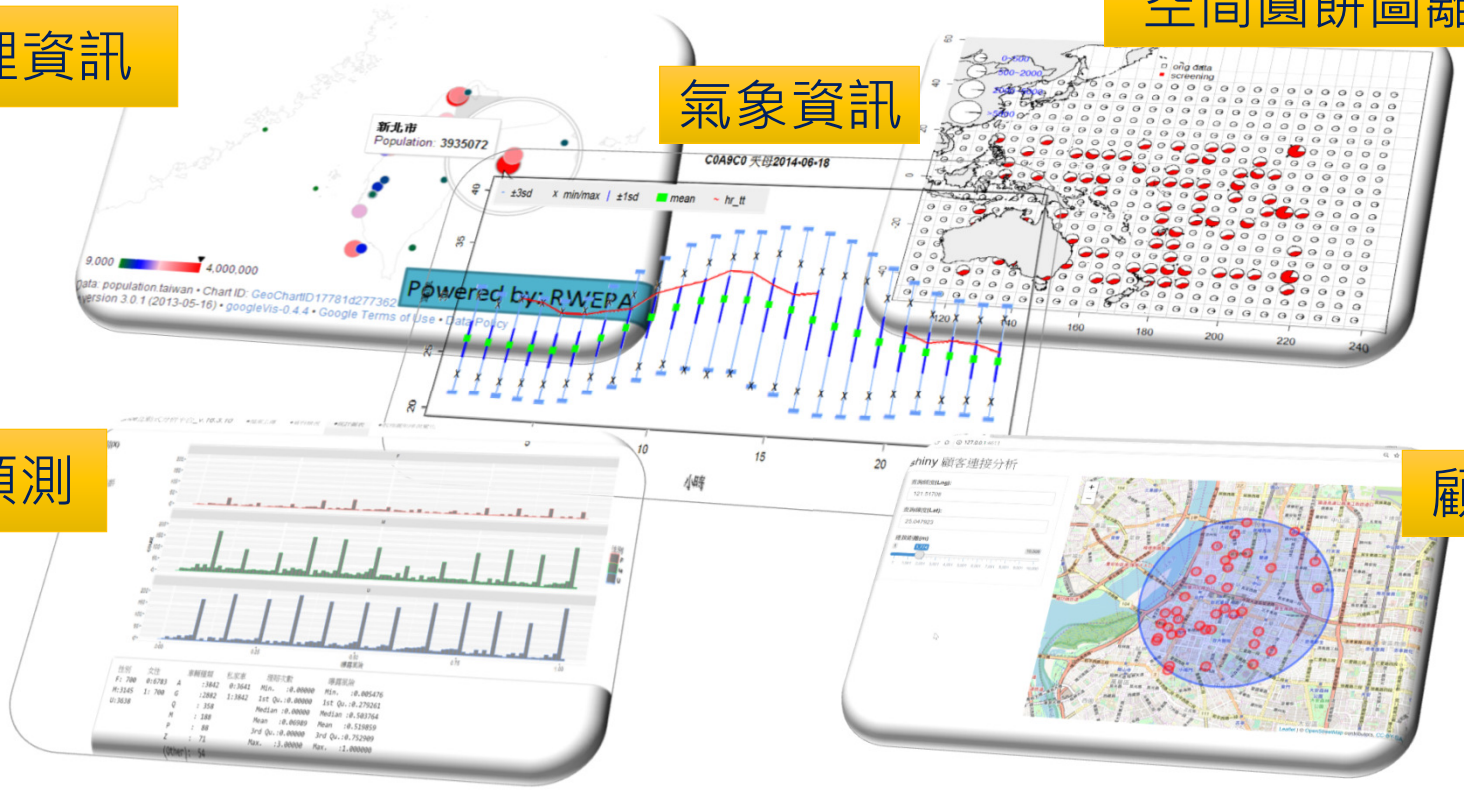

保險預測

顧客連結資訊

中央氣象局 1,600萬筆資料(14,328個檔案)

保險預測模型

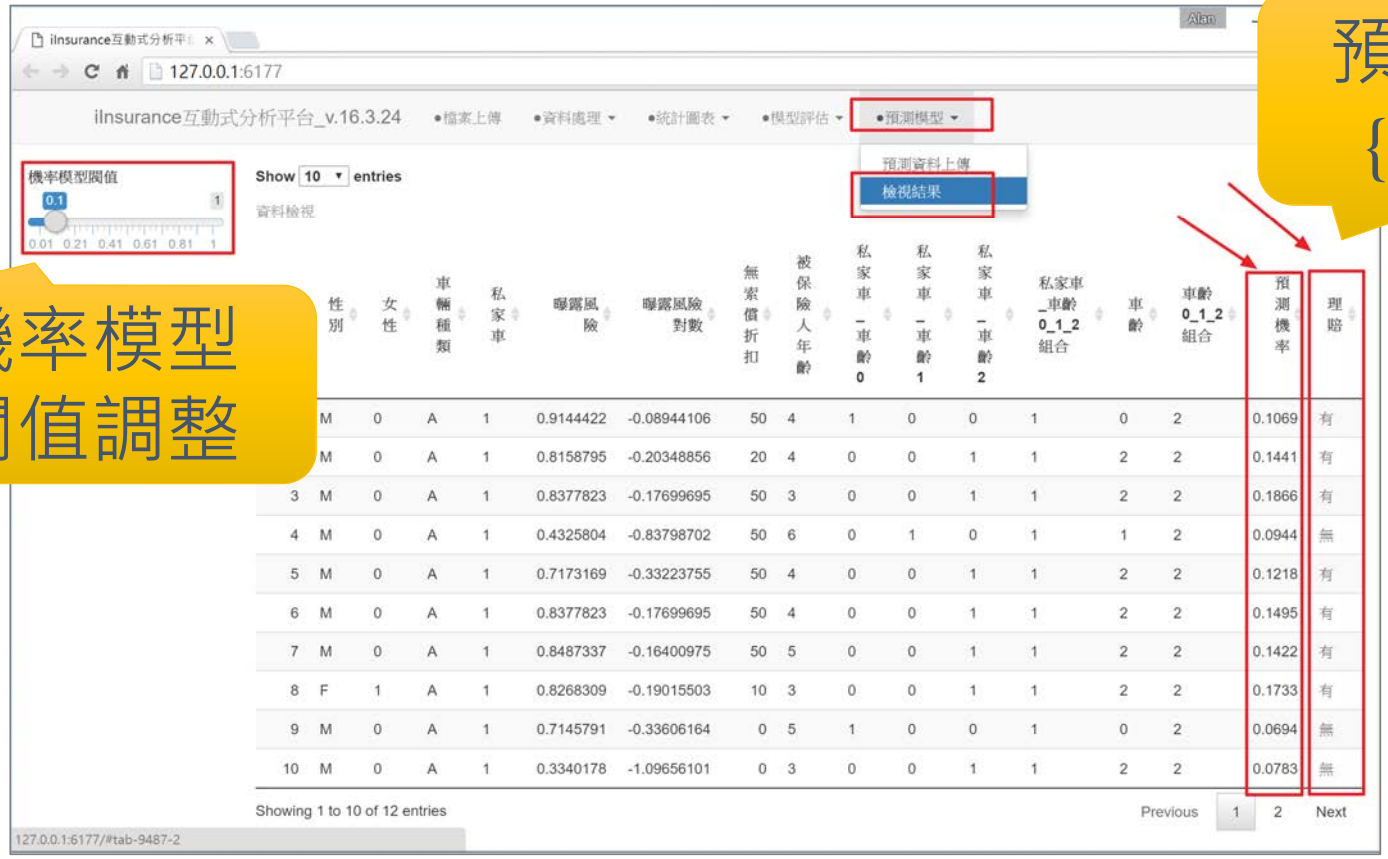
預測結果
{有,無}
機率模型
閥值調整
iInsurance互動式分析平台_v.16.3.24
檔案上傳
資料處理
統計圖表
模型評估
預測模型
預測資料上傳
檢視結果
機率模型閥值
Show 10 entries
資料檢視
性別
女性
車輛種類
私家車
曝露風險
曝露風險對數
無索償折扣
被保險人年齡
私家車_車齡0
私家車_車齡1
私家車_車齡2
私家車_車齡0_1_2組合
車齡
車齡0_1_2組合
預測機率
理賠
Showing 1 to 10 of 12 entries
Previous
Next

空間圓餅圖離群值分析

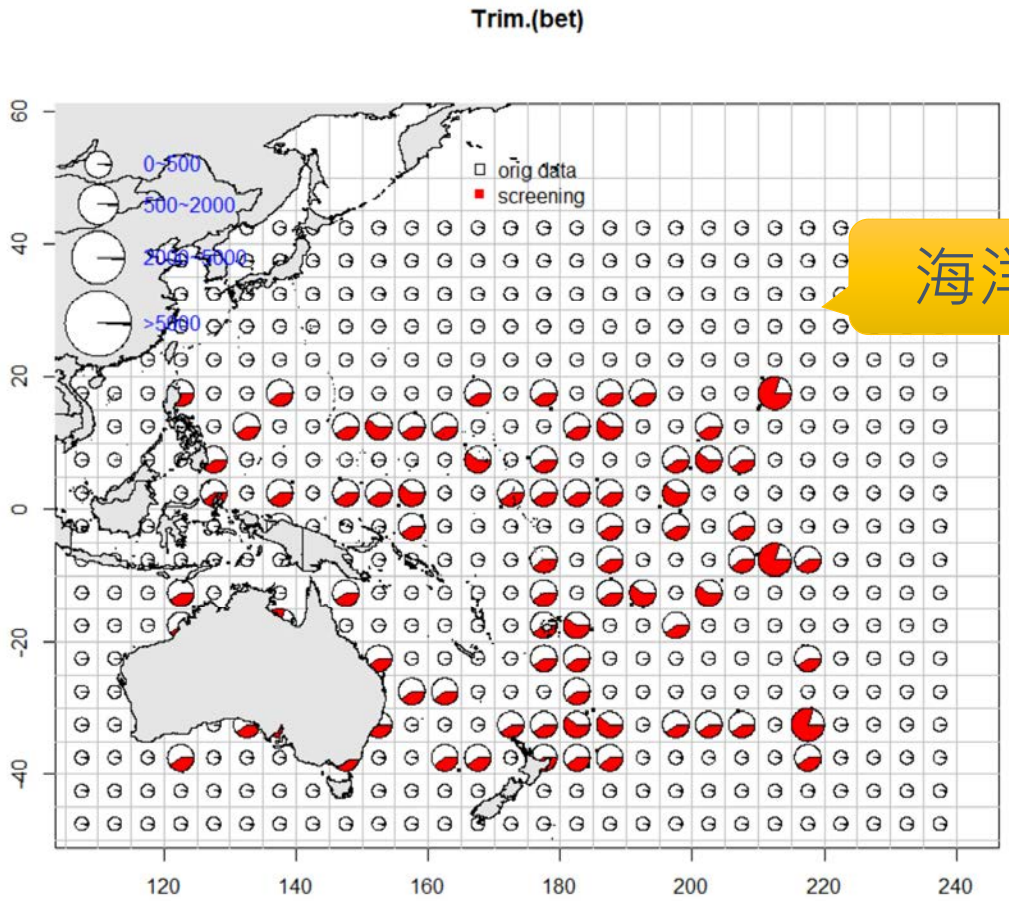

海洋生態視覺化

2020新型冠狀病毒視覺化

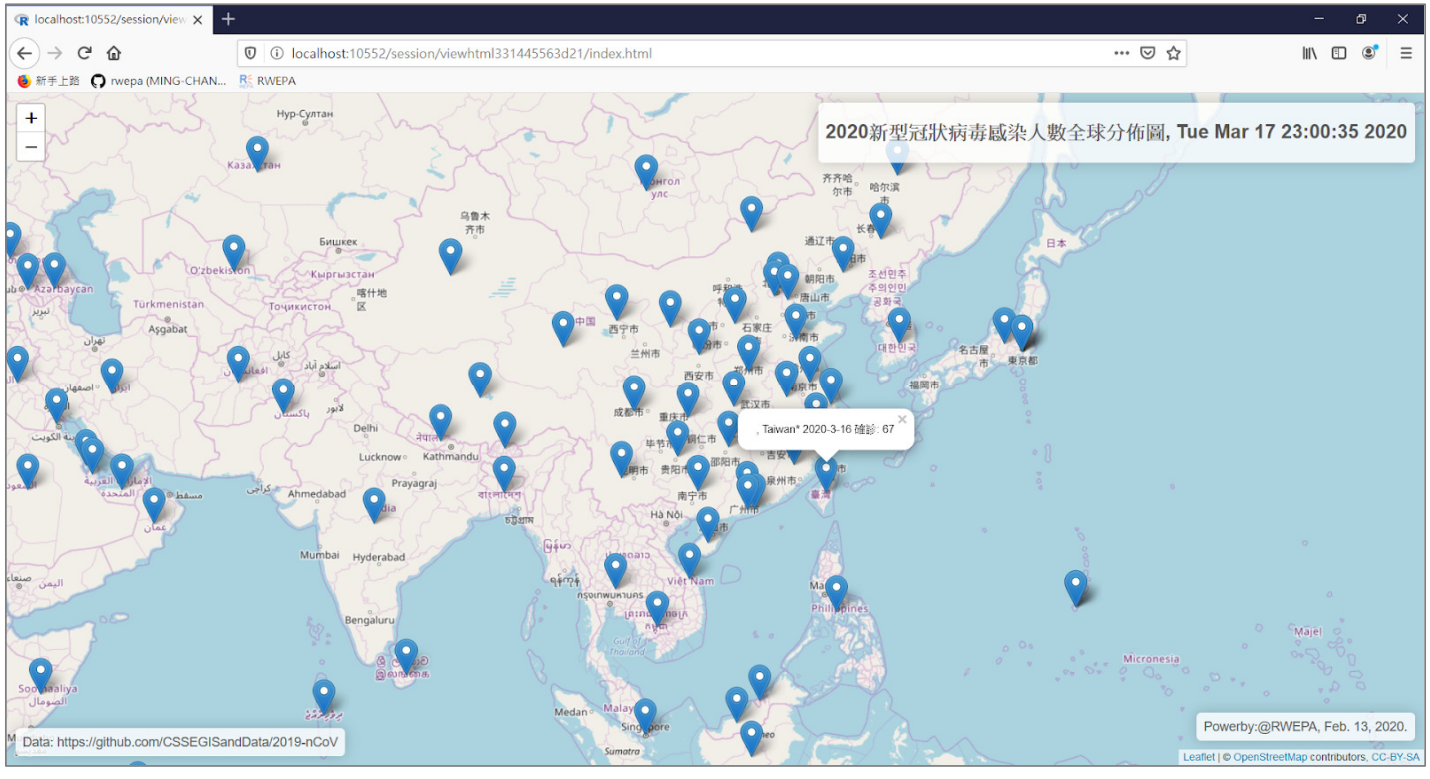

http://rwepa.blogspot.com/2020/02/2019nCoV.html

shiny 顧客連接分析

- https://rwepa.shinyapps.io/shinyCustomerConnect/

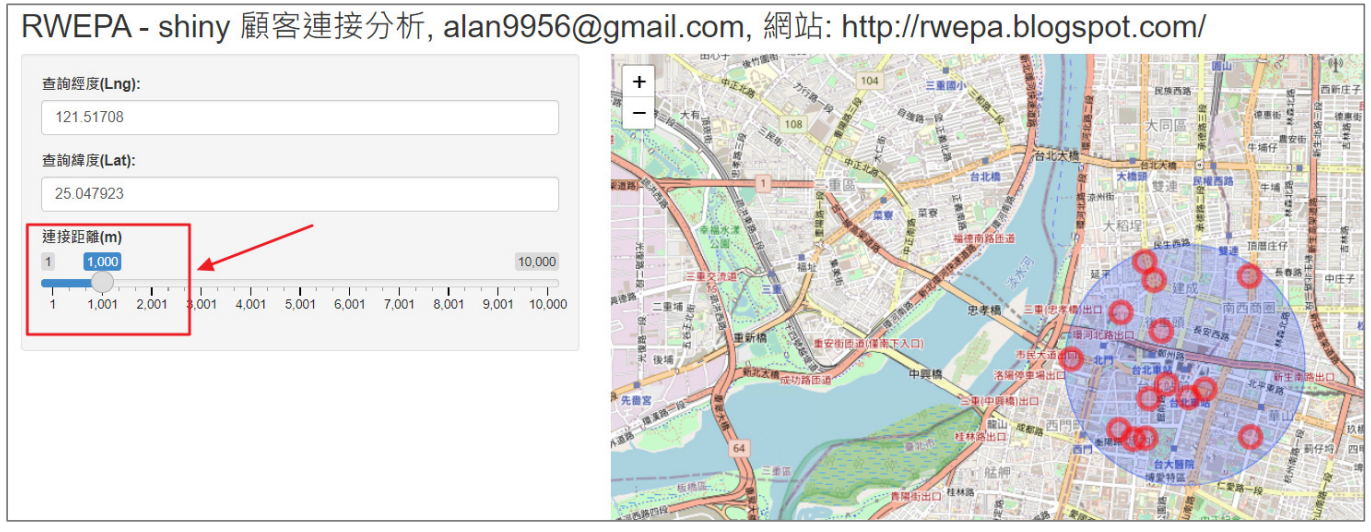

品質管制圖(quality control chart)應用

- 說明: http://rwepa.blogspot.com/2021/10/r-shiny-quality-control-chart.html
- 資料1: https://github.com/rwepa/shiny_spc/blob/main/data/spc_wafer_with_header.csv
- 資料2: https://github.com/rwepa/shiny_spc/blob/main/data/spc_pistonrings_without_header.csv
- 線上示範: https://rwepa.shinyapps.io/shiny_spc/

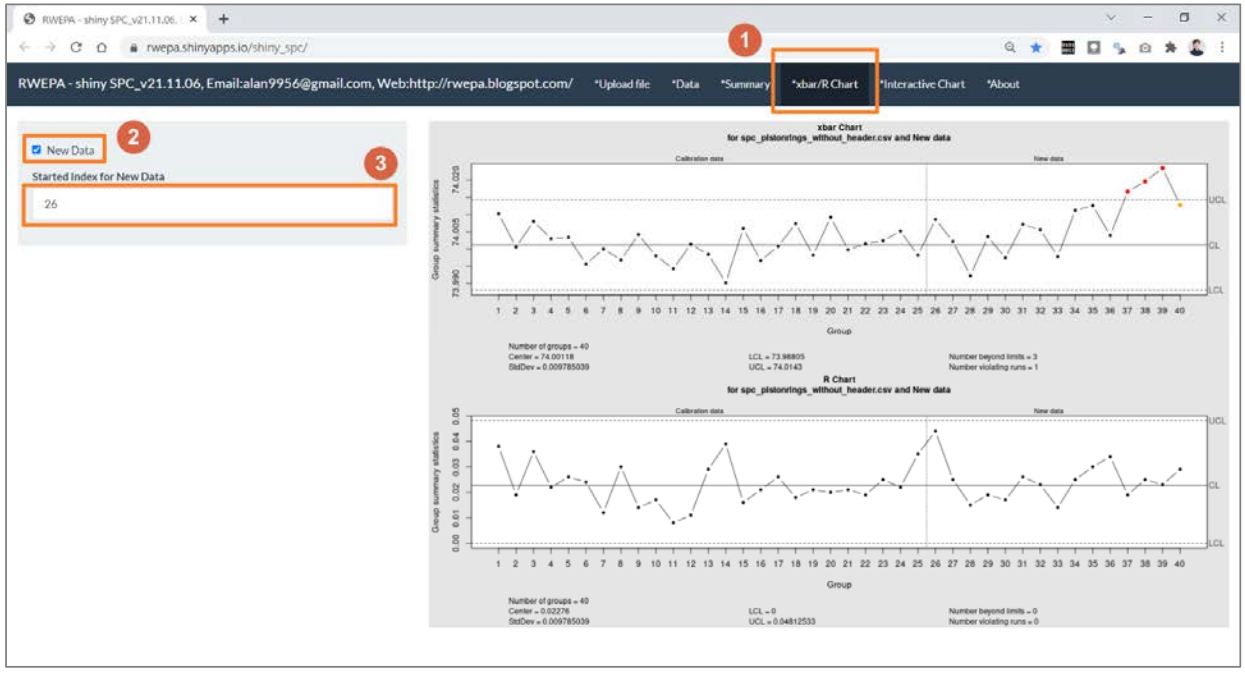

Taiwan Stock App

- https://rwepa.shinyapps.io/shinyStockVis/

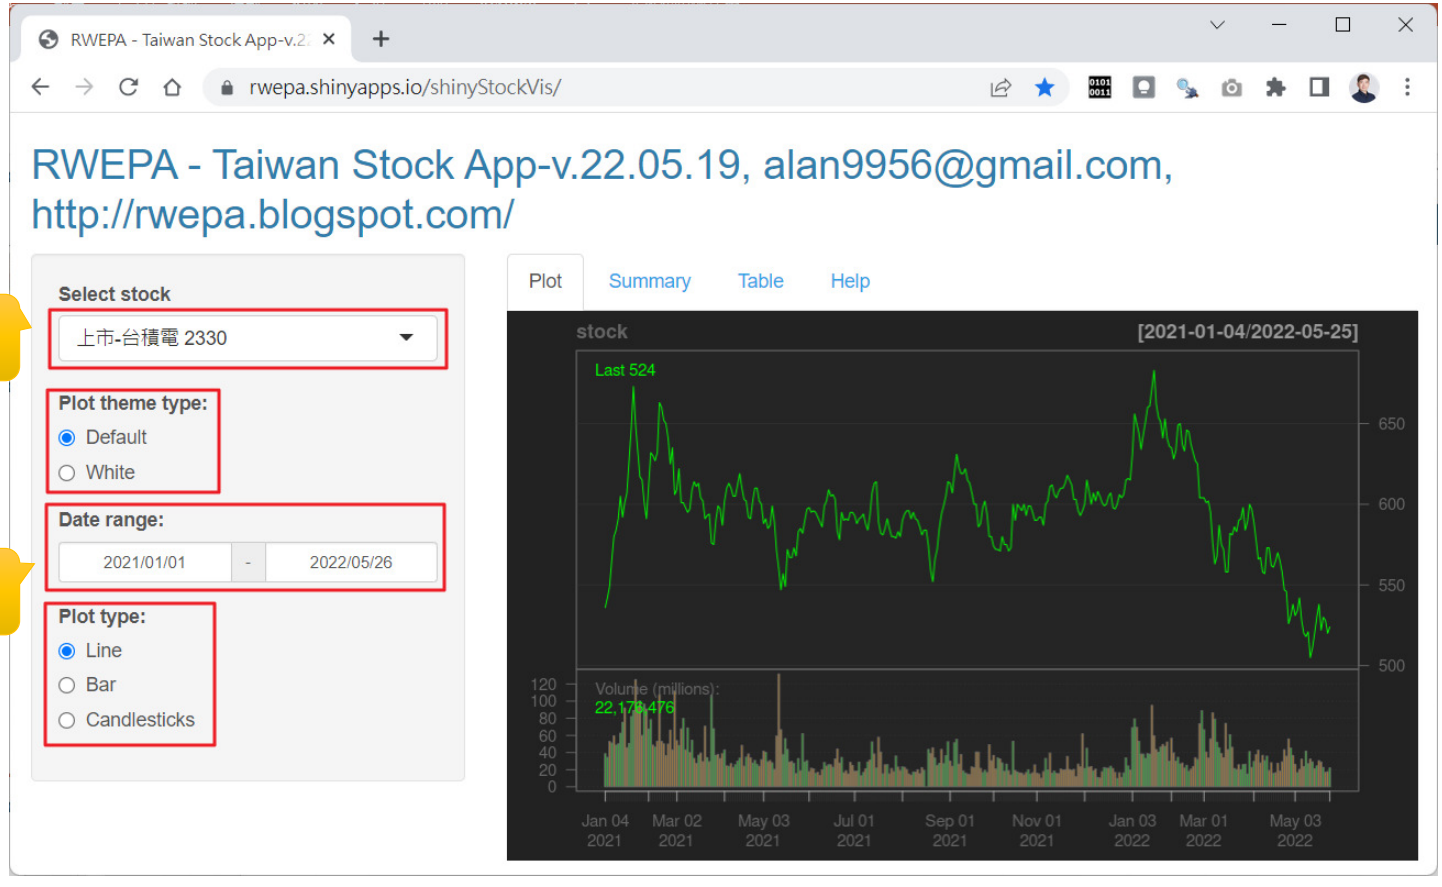

下拉式選單

日期範圍

離子資料分析與視覺化應用

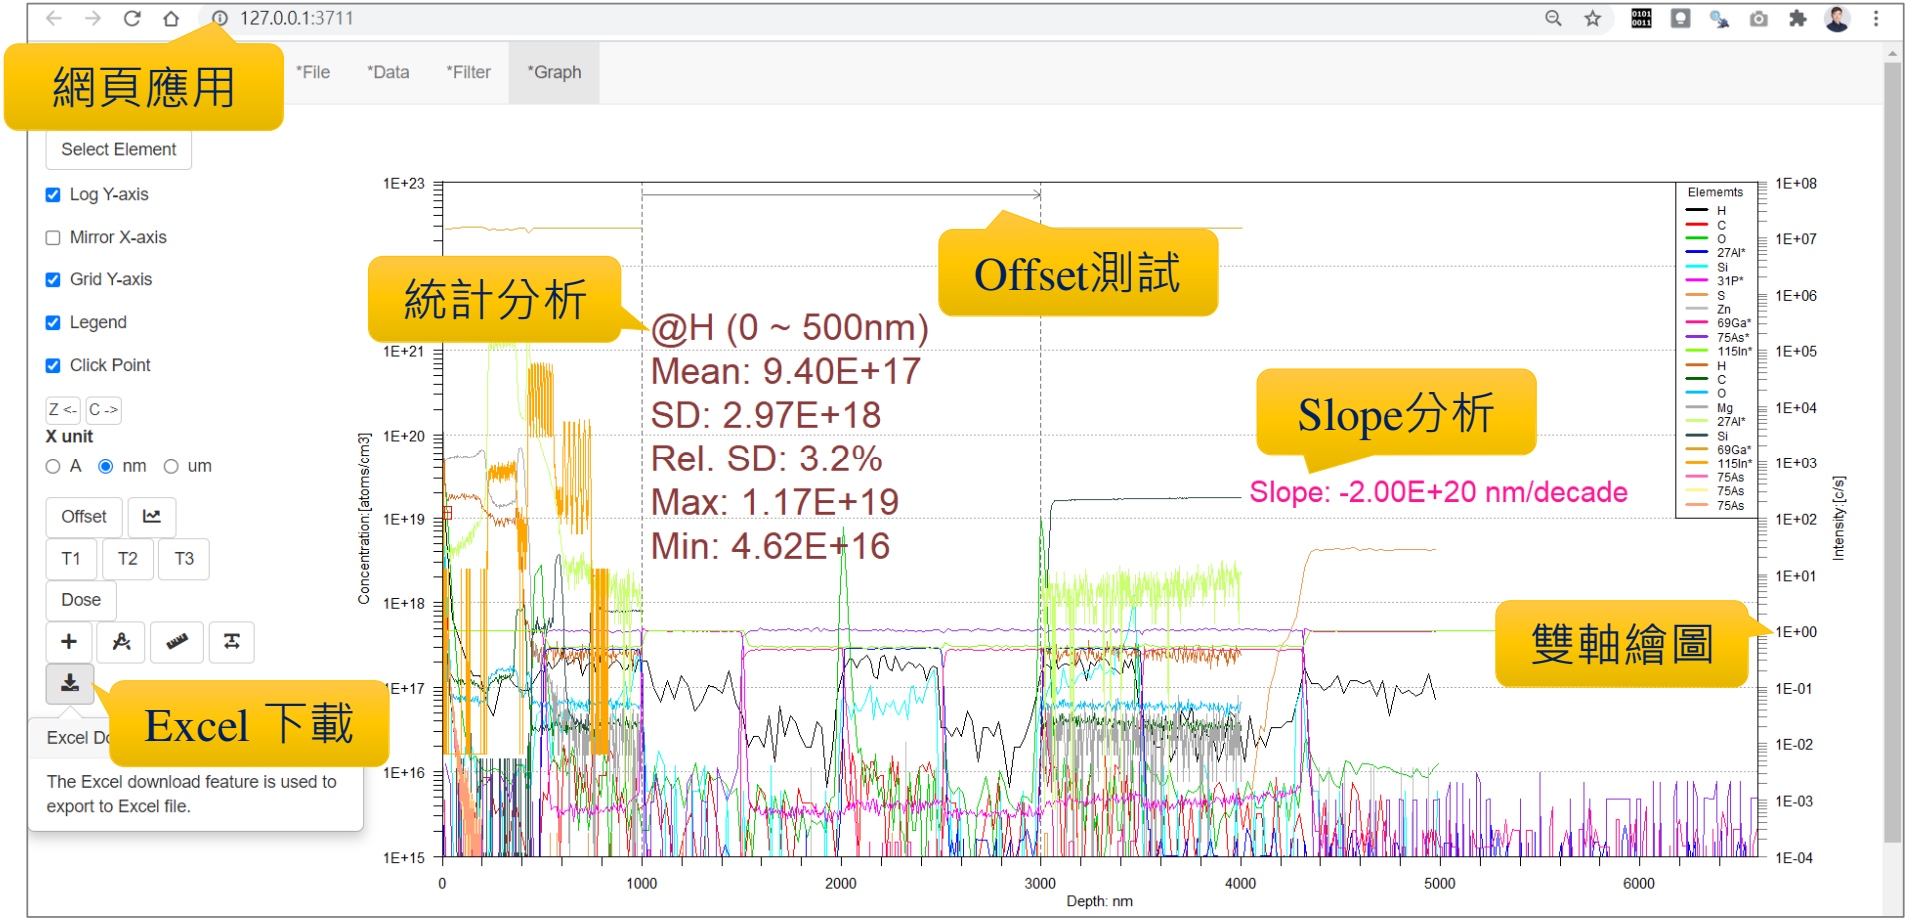

RWEPA | shiny企業實務應用 第4集-shiny銷售儀表板

- Shiny: https://rwepa.shinyapps.io/shinySalesDashboard/
- YouTube: https://youtu.be/4GgZlf8heQk

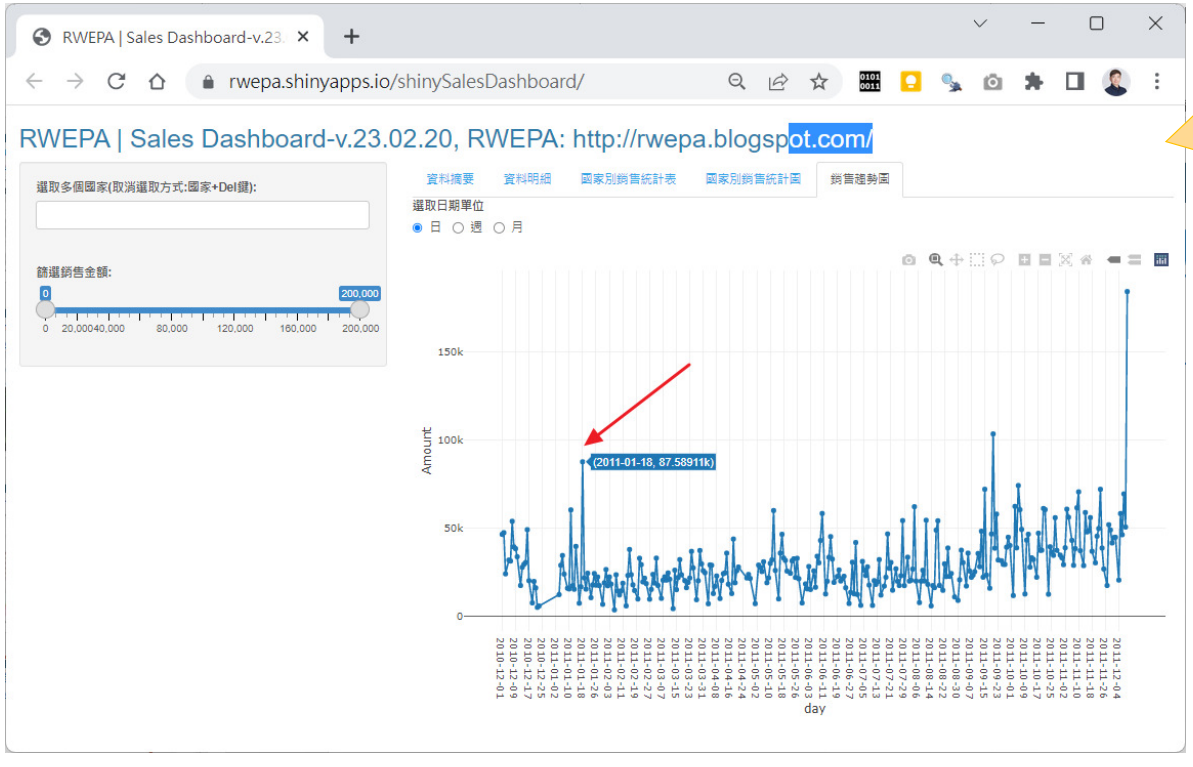

謝謝 ^_^

訂閱、讚、開啟小鈴鐺

shiny企業實務應用 第6集-小明算命師(下) - 第1季完結篇

- Ubuntu Shiny Server: https://shiny.rwepa.net/shiny-hr-teller/
- YouTube: https://youtu.be/rrD6KV3eV-w

Power BI - RFM分析

- 🌸 YouTube：https://youtu.be/Lkr9HmzLTtg
- 🌸 http://rwepa.blogspot.com/2023/07/rwepa-rfm-analysis-using-power-bi.html

Tableau - 智慧製造應用

- https://github.com/rwepa/Talks
- https://public.tableau.com/app/profile/ming.chang.lee/vizzes

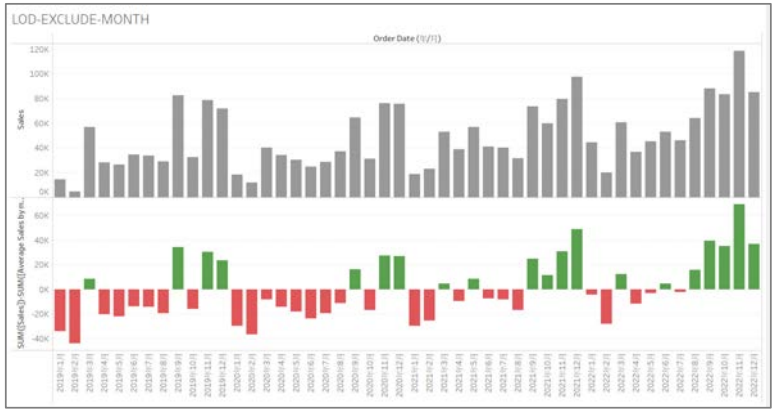

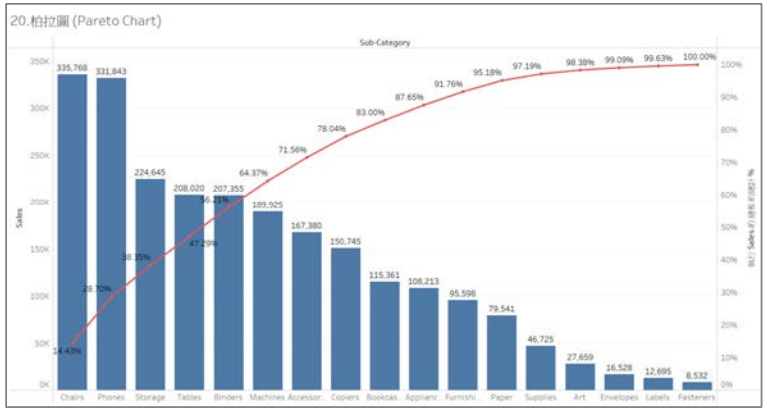

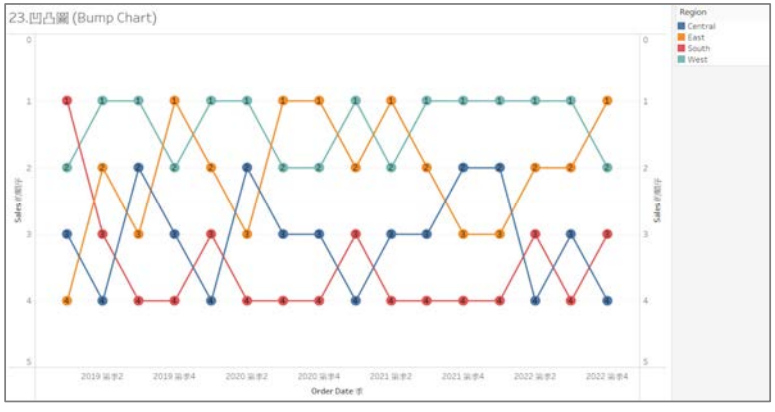

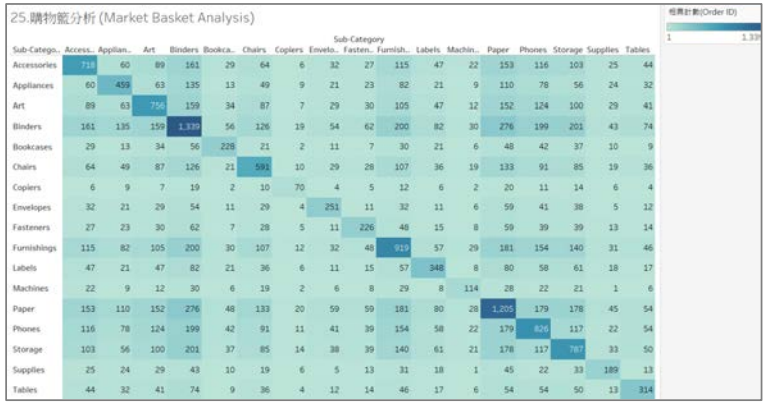

登山路線視覺化分析平台 (Python + Streamlit)

- YouTube：https://youtu.be/-_zghs2qrIg
- 系統展示 https://rwepa-climb.streamlit.app/

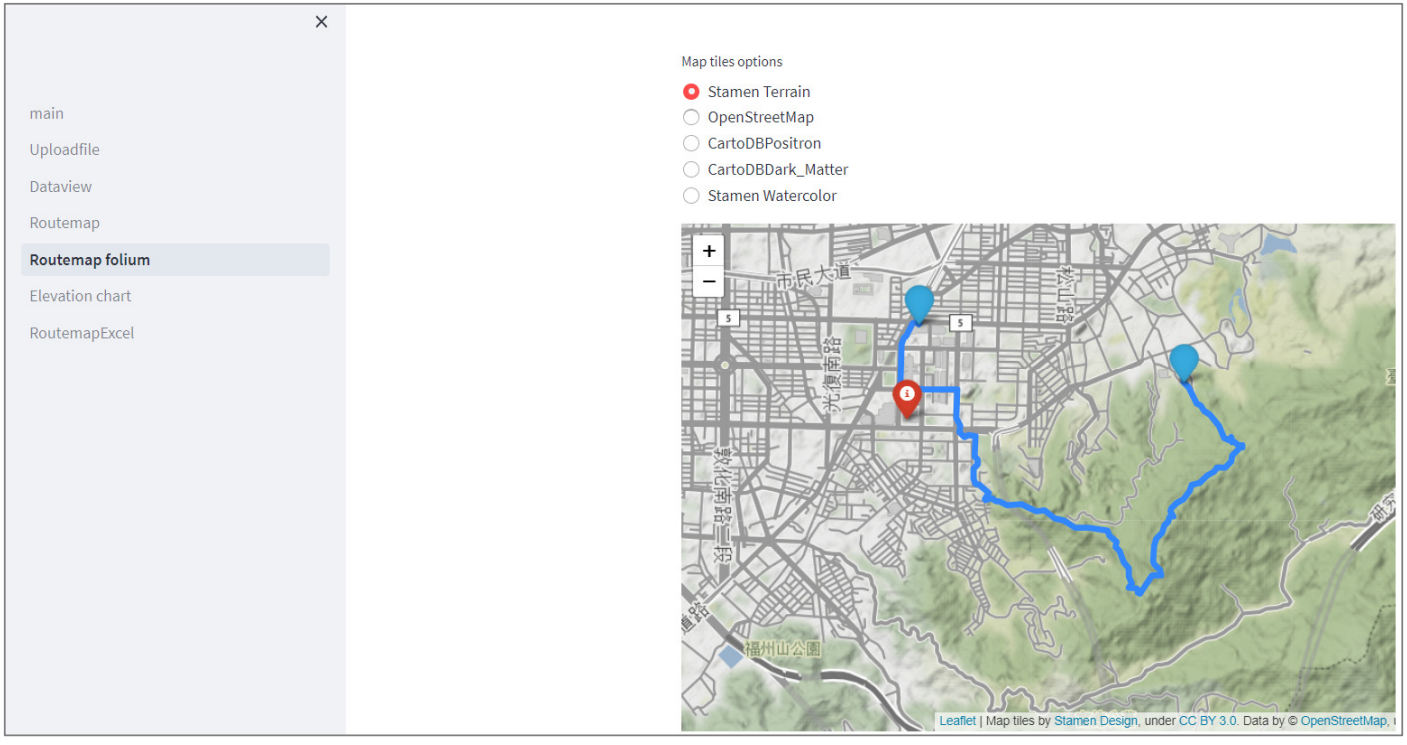

R 入門資料分析與視覺化應用(7小時28分鐘)

- https://mastertalks.tw/products/r?ref=MCLEE

課程提供教學範例的原始程式檔案與資料集
+中文字幕

- 主題

1. R, RStudio簡介與套件使用
2. 認識資料物件
3. 資料處理與分析
4. 資料視覺化應用

- 特色

1. 資料分析的**關鍵八步**
2. 提供必備**ggplot2**套件的應用知識與使用情境
3. 提供日期時間**zoo, xts套件**的整合應用操作
4. 提供**人力資源**資料與**銷售資料**，強化**實務資料**操作能力

R 商業預測應用(8小時53分鐘)

- https://mastertalks.tw/products/r-2?ref=MCLEE

課程提供教學範例的原始程式檔案與資料集
+中文字幕

- 主題

1. R，RStudio工具操作
2. 非監督式學習業預測
3. 監督式學習商業預測
4. 財金資料預測應用

- 特色

1. 採用**最有效率**方式學習大數據R語言，並應用於**職場資料分析**與**商業預測應用**
2. 提供**多元線性迴歸**的必備知識
3. 提供**財金資料商業預測應用**的基礎與進階必學技能
4. 提供學員人力資源資料與**台指期tick資料**預測演練

學習目標

2.AI與螺旋槳性能最佳化應用

大綱

- 2.1 螺旋槳資料集簡介
- 2.2 螺旋槳資料集下載
- 2.3 安裝模組
- 2.4 載入模組
- 2.5 匯入螺旋槳資料集
- 2.6 計算 solidity
- 2.7 資料視覺化
- 2.8 Solidity 遺漏值, 使用 KNN 填補法

https://simpleflying.com/how-an-airplane-propeller-works/

2.1 螺旋槳資料集簡介

- UIUC螺旋槳資料集: UIUC小型無人機和模型飛機上使用的螺旋槳的風洞測量
- UIUC: 伊利諾大學厄巴納 - 香檳分校（University of Illinois Urbana-Champaign）
- UIUC螺旋槳資料集下載(RWEPA GitHub)
- https://github.com/rwepa/DataDemo/tree/master/propeller_design
- ai_02_aeronautical_engineering.py

J vs. CT 散佈圖資料視覺化

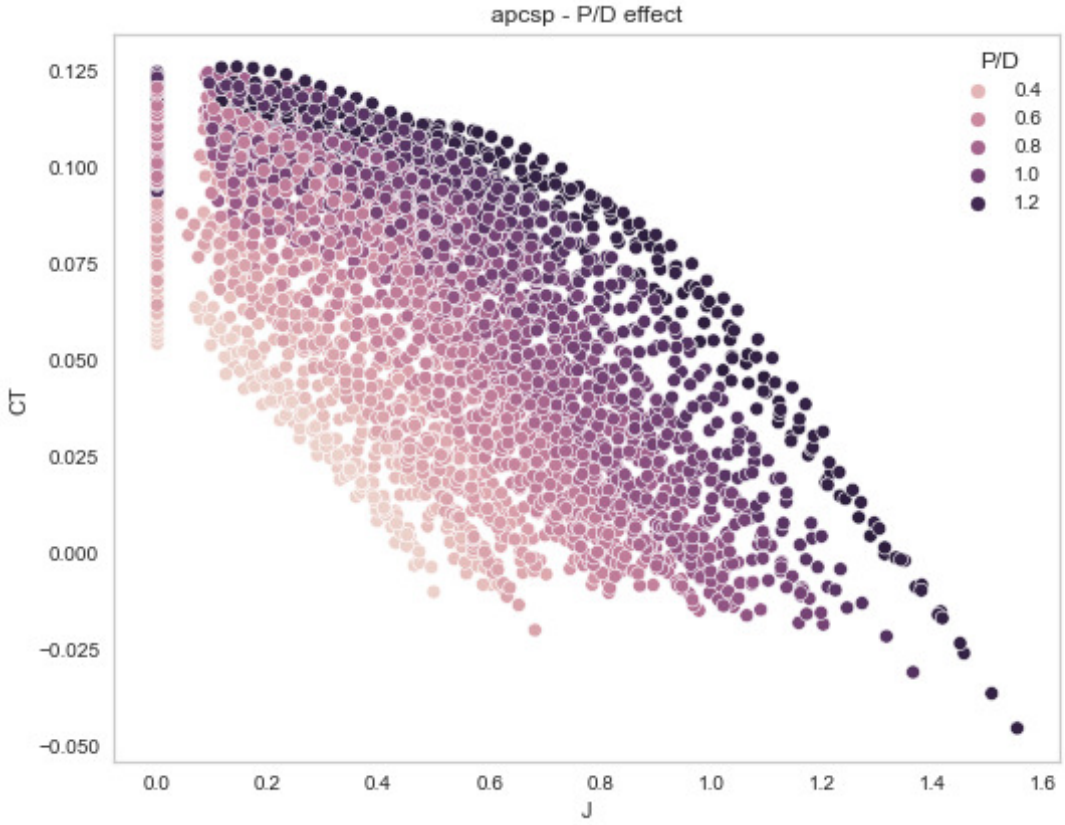

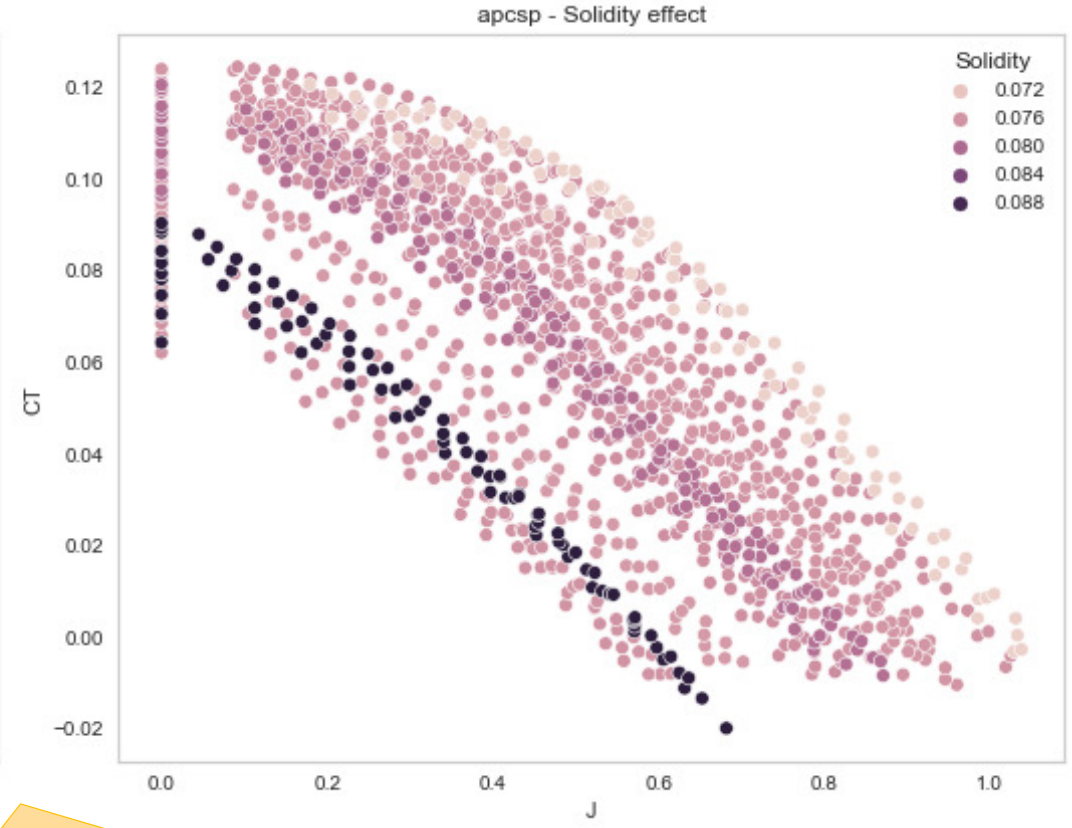

Python demo

相關係數圖-所有變數-視覺化

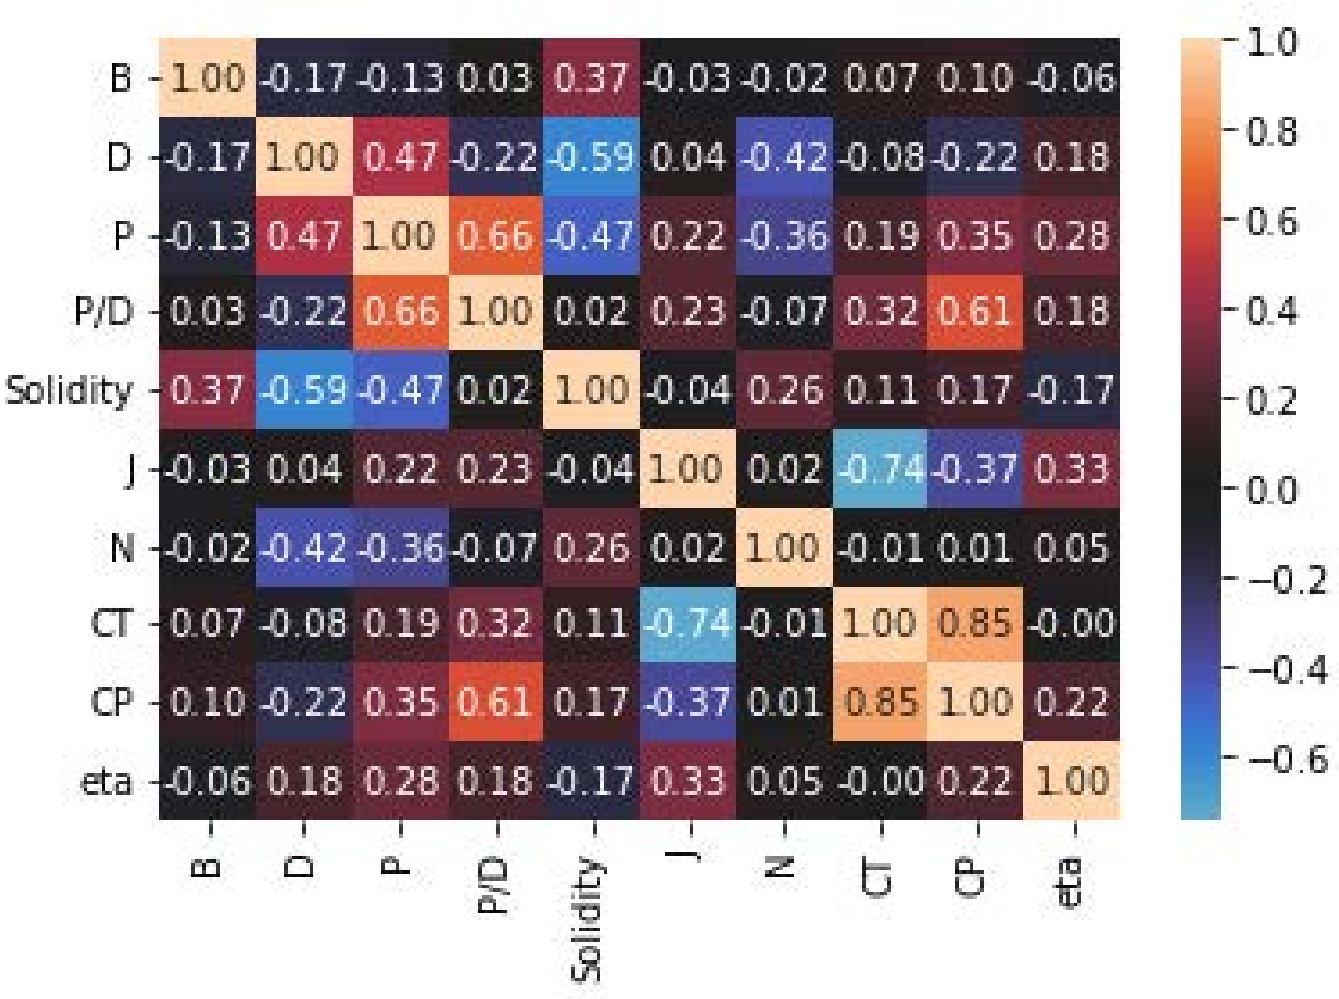

Python demo

3.AI與黃金價格深度學習預測應用(LSTM)

大綱

- 3.1 CRISP-DM 六大步驟
- 3.2 黃金價格深度學習預測應用(LSTM)
- 3.3 台灣股市,ETF下載

3.1 CRISP-DM 六大步驟

ai_03_gold_price.py

資料探勘生命週期 - CRISP-DM

- 跨產業資料探勘標準作業流程
  (CRoss Industry Standard Process for Data Mining)
- CRISP-DM是於1990年起，由SPSS以及NCR兩大廠商在合作戴姆克萊斯勒-賓士(Daimler Benz)的資料倉儲以及資料探勘過程中發展出來的。

CRISP-DM 資料探勘流程(續)

- 步驟 1：商業理解
- 步驟 2：資料理解
- 步驟 3：資料準備
- 步驟 4：模式建立
- 步驟 5：評估與測試
- 步驟 6：佈署應用

佔整專案時間的~80%

步驟3 資料準備

將資料隨機區分為二大類：

- 訓練資料70% (較大)
- 測試資料30% (較小)

CRISP-DM 資料探勘流程(續)

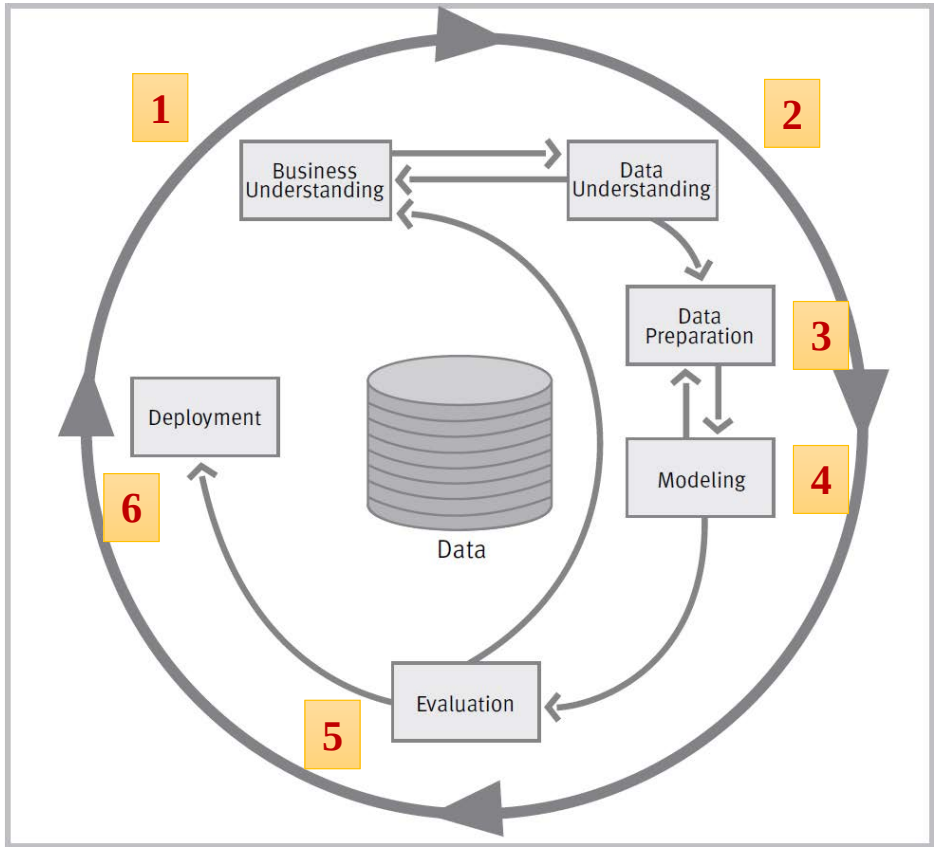

參考 https://en.wikipedia.org/wiki/Cross_Industry_Standard_Process_for_Data_Mining

數值模型績效指標

- 不可直接使用誤差的算術平均!

$$Total\ error = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)$$

- 均方誤差 (Mean Squared Error, MSE)

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- 均方根誤差 (Root Mean Squared Error, RMSE)

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

- 平均絕對誤差 (Mean Absolute Error, MAE)

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

類別模型績效指標 - 混淆矩陣

- http://rwepa.blogspot.com/2013/01/rocr-roc-curve.html

```
#            | 真實P類別  真實N類別
# ********************************
# 預測P類別  | TP真陽數   FP假陽數
# 預測N類別  | FN假陰數   TN真陰數
# ********************************
#             | P         N

# 1.TPR(True positive rate) 真陽性率, 愈大愈好 -----
# =TP/(TP+FN)
# =TP/P
# =Sensitivity 靈敏度
# =Recall 召回率
# =Probability of detection
# =Power
# 實際為陽性的樣本中，判斷為陽性的比例。
# 例如真正有生病的人中，被醫院判斷為有生病者的比例。
```

3.2 黃金價格深度學習預測應用(LSTM)

Yahoo 財金網站

- https://tw.stock.yahoo.com/
- 左上角輸入 GC=F
- 上漲金額 USD.13.20
- 上漲比例 0.64%

圖1. GC價格走勢圖(2013-2023年)

模型訓練, 正確率

```
Epoch 1/150
WARNING:tensorflow:From C:\Users\asus\anaconda3\Lib\site-packages\keras\src\utils\tf_utils.py:492:
The name tf.ragged.RaggedTensorValue is deprecated. Please use
tf.compat.v1.ragged.RaggedTensorValue instead.

70/70 [==============================] - 13s 64ms/step - loss: 0.0459 - val_loss: 0.0705
Epoch 2/150
70/70 [==============================] - 3s 41ms/step - loss: 0.0123 - val_loss: 0.0325
Epoch 3/150
70/70 [==============================] - 3s 42ms/step - loss: 0.0065 - val_loss: 0.0164
Epoch 4/150
70/70 [==============================] - 3s 42ms/step - loss: 0.0039 - val_loss: 0.0103
Epoch 5/150
70/70 [==============================] - 3s 46ms/step - loss: 0.0028 - val_loss: 0.0075
Epoch 6/150
70/70 [==============================] - 5s 73ms/step - loss: 0.0023 - val_loss: 0.0074
```

```
In [44]:
    ...: print("Test Loss:", result)
    ...: print("Test MAPE:", MAPE)
    ...: print("Test Accuracy:", Accuracy)
Test Loss: 0.0006855355459265411
Test MAPE: 0.021935985195150547
Test Accuracy: 0.9780640148048495
```

正確率: 97.8%

Python demo

實際與預測比較圖

圖4. Model Performance on Gold Price Prediction

3.3 台灣股市,ETF下載

元大台灣50ETF走勢圖

4.結論

學習心得

- 資料分析暨視覺化的心法- APC方法
- 螺旋槳性能最佳化應用 – 資料分析群組、視覺化
- 黃金價格深度學習預測應用(LSTM)、ETF下載與視覺化

Python 常用模組

模組	功能
Numpy	Large, multi-dimensional arrays and matrices
Scipy	Optimization, linear algebra, integration, FFT, signal
Pandas	DataFrame object for data manipulation
Matplotlib	Static, animated, and interactive visualizations
Statsmodels	Statistical models
Scikit-learn	Machine learning library
Tensorflow, PyTorch	Deep learning
Biopython	Biological computation
Scanpy	Single-cell analysis
Django, Flask, Streamlit	Web
Plotly, dash, bokeh	Interactive visualization

參考資料

- RWEPA
  - http://rwepa.blogspot.com/
- Python 程式設計-李明昌 <免費電子書>
  - http://rwepa.blogspot.com/2020/02/pythonprogramminglee.html
- iPAS Python programming <免費教材>
  - https://github.com/rwepa/ipas_bda/blob/main/ipas-python-program.py
- RWEPA | 登山路線視覺化分析平台 (Python + Streamlit) 【中文字幕】
  - YouTube: https://youtu.be/-_zghs2qrIg
  - Link: https://rwepa.blogspot.com/2023/08/visualization-climbing-routes-with.html
- 投影片: https://github.com/rwepa/DataDemo/tree/master/propeller_design

謝謝您的聆聽

Q & A

李明昌

alan9956@gmail.com

http://rwepa.blogspot.tw/